

Data Engineer

Parcours de formation générique



NOS VALEURS

Partage

Entraide

Solidarité

Implication

Remise en question

Confiance


L'ORGANISME DE FORMATION

Simplon.co

55 rue de Vincennes
93100 Montreuil

CONTACT

Directeur/trice d'impact Unit



PUBLICS CONCERNÉS

→ Toute personne inscrite comme demandeur.se d'emploi

PRÉ-REQUIS

Afin d'intégrer le dispositif de formation ou pour suivre une formation, le candidat doit :

- soit être titulaire d'un titre ou d'un diplôme de niveau 5 en informatique avec une expérience professionnelle d'un an minimum dans le secteur des systèmes et réseaux informatiques.
- soit être titulaire d'un titre ou d'un diplôme de niveau 6 en informatique.

Dans le cas où un candidat ne disposerait pas des prérequis définis, il a la possibilité de déposer un dossier de candidature qui sera examiné par une commission en vue d'une admission « exceptionnelle ».


Les candidats au parcours devront justifier, par le diplôme ou l'expérience professionnelle, des compétences suivantes :

- Compétences en gestion de projet :
 - Animer des rendez-vous avec le(s) client(s) afin d'identifier les besoins.
 - Rédiger une réponse technique.
 - Suivre le planning et le respect des contraintes.
 - Assurer le lien entre le client et les équipes pendant toute la durée de conception du projet.
- Compétences techniques :
 - Installer et gérer des services
 - suivi d'une documentation technique
 - application d'une procédure
 - test, déploiement, documentation, monitoring

- Programmer des scripts d'automatisation dans un langage ou un environnement quelconque (win, unix...)
 - programmation procédurale (sans architecture logiciel)
- Concevoir et créer des bases de données
 - modélisation : MERISE, entités-relations, approche orientée requêtes...
 - installation et paramétrage d'un SGBD à partir d'une modélisation
- Maîtriser SQL (ou équivalent) à un niveau fondamental
 - CRUD (Create, Read, Update, Delete)
 - Création de table, imports / exports, méta-data...
- Manipuler des données dans un but de qualification de jeux de données
 - qualification d'un jeu de données (exploitabilité, volume...)
 - conception du formatage des données nécessaire pour répondre à une problématique métier

DURÉE ET RYTHME

5,5 mois en formation intensive et 5 de stage



LE MÉTIER DE DATA ENGINEER

A l'issue de la formation, l'apprenant·e sera en capacité de mettre en œuvre les compétences du ou de la data engineer.

Cette formation vise :

- La certification professionnelle de niveau 7 [RNCP-37638](#) : “Expert en infrastructures de données massives”

Le Data Engineer est un ingénieur spécialisé dans la conception de solutions répondant à un besoin de stockage, d'organisation, d'accès, d'agrégation, de protection et d'analyse de données. Ce besoin découle de la massification récente des données disponibles, phénomène désigné sous le nom de big data. Le Data Engineer vient se positionner entre les administrateurs IT (technologies de l'information) qui fournissent une infrastructure IT opérationnelle et les data analysts/scientists qui vont exploiter les données. Premier acteur du processus de traitement de la donnée, son travail intervient en amont de l'exploitation des données (data analysts/scientists), directement après que l'infrastructure technique ait été mise en œuvre par les architectes et les administrateurs. La finalité du Data Engineer est de rendre les données faciles d'accès et prêtes à l'analyse par ses clients internes (notamment les data analysts/scientists).

La mission principale du Data Engineer est la création des flux de collecte, de nettoyage et de stockage des données. En fonction de la taille de l'entreprise et des données à manipuler, le Data Engineer structure et alimente une base de données analytique, un entrepôt de données ou encore un lac de données.

Le Data Engineer peut travailler pour des startups, des PME, des grands comptes, des cabinets de conseil et des ESN/SSII.

Le métier de Data Engineer s'articule alors autour de 4 activités principales :

- Piloter la conduite d'un projet data
- Réaliser la collecte, le stockage et la mise à disposition des données d'un projet data
- Élaborer et maintenir un entrepôt de données (data warehouse)
- Encadrer la collecte massive et la mise à disposition des données issues de l'activité de l'organisation avec un *data lake*

Pour réaliser ces activités, le.a Data Engineer doit s'appuyer sur les compétences suivantes :

- **C1. Analyser l'expression d'un besoin de projet data** dans une étude de faisabilité en explorant, à l'aune des enjeux stratégiques de l'organisation, le besoin métier avec les parties prenantes pour valider les orientations et sélectionner les hypothèses techniques du projet avec le ou les commanditaire(s).
- **C2. Cartographier les données disponibles** en référençant les usages, les sources, les métadonnées et les données, afin de valider les hypothèses techniques du projet data
- **C3. Concevoir un cadre technique d'exploitation des données** en analysant les contraintes techniques, de moyens et la cartographie des données afin de définir une réponse technique adaptée aux ressources mobilisables dans le respect du RGPD et d'une démarche éco-responsable.
- **C4. Réaliser une veille technique et réglementaire** en sélectionnant des sources et en collectant et traitant les informations collectées afin de formuler des recommandations projet toujours en phase avec l'état de l'art
- **C5. Planifier la réalisation d'un projet data** en attribuant les moyens nécessaires et en définissant les étapes de réalisation et les méthodes de suivi du projet afin d'organiser sa mise en oeuvre
- **C6. Superviser la réalisation d'un projet data** en organisant les méthodes, les outils de travail et la communication entre les parties prenantes, afin d'accompagner les membres de l'équipes dans la réussite du projet
- **C7. Communiquer tout au long de la réalisation du projet data** sur les orientations, les réalisations et leurs impacts en élaborant la stratégie et les supports de communication afin d'informer toutes les parties prenantes des évolutions ou des opportunités internes comme externes, portés par le projet
- **C8. Automatiser l'extraction de données depuis un service web, une page web (scraping), un fichier de données, une base de données et un système big data** en programmant le script adapté afin de pérenniser la collecte des données nécessaires au projet.
- **C9. Développer des requêtes de type SQL* d'extraction des données** depuis un système de gestion de base de données et un système big data en appliquant le langage de requête propre au système afin de préparer la collecte des données nécessaires au projet.

- **C10. Développer des règles d'agrégation de données** issues de différentes sources en programmant, sous forme de script, la suppression des entrées corrompues et en programmant l'homogénéisation des formats des données afin de préparer le stockage du jeu de données final.
- **C11. Créer une base de données** dans le respect du RGPD en élaborant les modèles conceptuels et physiques des données à partir des données préparées et en programmant leur import afin de stocker le jeu de données du projet.
- **C12. Partager le jeu de données** en configurant des interfaces logicielles et en créant des interfaces programmables afin de mettre à disposition le jeu de données pour le développement du projet.
- **C13. Modéliser la structure des données d'un entrepôt de données** en s'appuyant sur les dimensions et les faits afin d'optimiser l'organisation des données pour les requêtes analytiques.
- **C14. Créer un entrepôt de données** à partir des paramètres du projet, des contraintes techniques et matérielles et de la modélisation de la structure des données afin de soutenir l'analyse de l'activité et l'aide à la décision stratégique de l'organisation
- **C15. Intégrer les ETL nécessaires en entrée et en sortie d'un entrepôt de données** afin de garantir la qualité et le bon formatage des données en accord avec les modélisations logiques et physiques préalablement établies
- **C16. Gérer l'entrepôt de données** à l'aide des outils d'administration et de supervision dans le respect du RGPD, afin de garantir les bons accès, l'intégration des évolutions structurelles et son maintien en condition opérationnelle dans le temps.
- **C17. Implémenter des variations dans les dimensions de l'entrepôt de données** en appliquant la méthode adaptée en fonction du type de changement demandé afin d'historiser les évolutions de l'activité de l'organisation et maintenir ainsi une bonne capacité d'analyse.
- **C18. Concevoir l'architecture du data lake** en sélectionnant les technologies appropriées en fonction de la volumétrie, de la variété et de la vitesse des données dans le but de définir l'architecture technique optimale à intégrer.
- **C19. Intégrer les différents composants d'infrastructure du data lake** en appliquant la procédure adaptée, afin d'assurer l'acquisition, le stockage et la mise à disposition du catalogue de données
- **C20. Gérer le catalogue des données** en tenant compte de leur nature, de leurs sources d'alimentation et de leur cycle de vie, dans le respect du RGPD, afin de garantir les fonctionnalités du service.
- **C21. Implémenter les règles de gouvernance des données** en sécurisant la recherche, la récupération et l'ajout de données afin de respecter les règles de gouvernance des données de l'organisation, dans le cadre du déploiement de la politique de protection des données.

MOBILISER DES COMPÉTENCES TRANSVERSALES, FONDAMENTALES EN ENVIRONNEMENT PROFESSIONNEL

Les compétences transversales sont identifiées en situation d'apprentissage imitant la situation professionnelle, pour être mobilisées par les apprenants, évaluées et valorisées tout au long du parcours de formation, au même titre que les autres compétences professionnelles visées par la formation.

3 activités principales sont ainsi identifiées :

- Organiser le travail individuel et collectif en environnement professionnel.
- Adopter une démarche de résolution face à un problème.
- Communiquer à l'oral et à l'écrit en environnement professionnel

Pour réaliser ces activités, le professionnel du secteur numérique doit s'appuyer sur les compétences que nous avons identifiées dans les différentes activités professionnelles auxquelles nous formons les apprenants :

- **CT1. Planifier le travail à effectuer** individuellement et en équipe afin d'optimiser le travail nécessaire à l'atteinte de l'objectif visé, à l'aide des outils numériques adaptés .
- **CT2. Contribuer au pilotage de l'organisation du travail** individuel et collectif afin de faciliter la communication, la collaboration et la gestion des imprévus au sein de l'équipe
- **CT3. Définir le périmètre d'un problème rencontré** en adoptant une démarche inductive afin de permettre la recherche de solution
- **CT4. Rechercher de façon méthodique des pistes de résolutions** au problème rencontré afin de le résoudre
- **CT5. Partager la solution adoptée** en utilisant les moyens de partage de connaissance ou de documentation disponibles afin de contribuer au développement de la connaissance de l'entreprise.
- **CT6. Présenter un travail réalisé** en synthétisant ses résultats, sa démarche et en répondant aux questions afin de le restituer au commanditaire
- **CT7. Se familiariser avec les codes et la culture propres à son environnement professionnel** afin d'y faciliter son intégration
- **CT8. Interagir dans un contexte professionnel** de façon respectueuse et constructive pour favoriser la collaboration
- **CT9. Faciliter un temps de travail collectif** en assurant une communication constructive entre les participants dans un cadre de travail clair pour permettre l'implication de tous

L'ENVIRONNEMENT TECHNIQUE DE LA FORMATION

Les environnements techniques possibles en formation sont toujours adaptés au projet (bassin d'emplois local, entreprises partenaires...).

Voici un exemple d'environnement technique envisageable pour ce parcours formation :

	Stockage	Transformation & Analyse	Déploiement et Orchestration
Solutions Azure	• Azure Data Lake Storage • Azure Blob	• Azure Synapse Analytics • Azure Databricks • Microsoft Power BI	• Microsoft Fabric • Azure Data Factory • Azure Stream Analytics
Solutions hors plateforme	• Relationnel : PostgreSQL • Big data : HDFS, MongoDB, Databricks, Apache Hive.	Extraction : Airbyte, Talend, spark, hive, SQL Transformation : dbt, spark, hive, sql, python	• Kubernetes, docker, Airflow, Dagster, • bash, cron, python

Certains outils sont payants (Talend, Databricks) - prendre la version gratuite ou la version d'essai (souvent limitée à 14 jours) - ajuster la durée des briefs en fonction.

DÉTAILS DU PROGRAMME DE FORMATION

Table des matières

Phase 0 - La prairie - introduction du parcours de formation - 49 heures.....	11
Phase 1 - Intervenir sur des ETL et des bases de données les faire évoluer - 70 heures.....	14
Phase 2 - Intervenir sur un data warehouse et le faire évoluer - 98 heures.....	18
Phase 3 - Intervenir sur un data lake et le faire évoluer - 133 heures.....	22
Phase 4 - Concevoir et créer des ETL, des bases de données et la mise à disposition des données aux équipes d'analyse - 98 heures.....	27
Phase 5 - Concevoir et créer un data warehouse - 105 heures.....	31
Phase 6 - Concevoir et créer un data lake - 105 heures.....	35
Phase 7 - Mener des missions d'étude, de conseil et d'intégration en systèmes de stockage et big data - 70 heures.....	40
Phase 8 - Stage - 665 heures.....	44
Phase 9 - Préparation et examen de certification - 70 heures.....	45

Phase 0 - La prairie - introduction du parcours de formation - 49 heures

Modalité : **face à face pédagogique**, en centre de formation

La Prairie est le premier temps de la formation où les apprenant·e·s prennent leurs marques.

À la fin de La Prairie, les apprenant·e·s auront :

- Installé leur environnement de travail, dont notamment les outils et/ou le matériel nécessaires à l'adaptation du poste de travail en fonction des besoins spécifiques de chacun des apprenant·e·s
- compris le métier et surtout des compétences visées par le parcours de formation
- compris l'évaluation finale (certification) visée par le parcours de formation
- vécu une introduction à la pédagogie Simplon
- participé à l'émergence de la dynamique collective, de promotion
- découvrir les méthodes agiles pour l'organisation du travail
- se préparer à la FOAD

Compétences du référentiel visées par la phase 0 - La Prairie :

- **C4.** Réaliser une veille technique et réglementaire - *niveau 1*
- **C7.** Communiquer tout au long de la réalisation du projet data - *niveau 1*
- **C8.** Automatiser l'extraction de données - *niveau 1*
- **C9.** Développer des requêtes de type SQL* d'extraction des données - *niveau 1*
- **C10.** Développer des règles d'agrégation de données - *niveau 1*
- **C11.** Créer une base de données - *niveau 1*
- **CT1.** Planifier le travail à effectuer individuellement et en équipe - *niveau 1*
- **CT2.** Contribuer au pilotage de l'organisation du travail individuel et collectif - *niveau 1*
- **CT3.** Définir le périmètre d'un problème rencontré en adoptant une démarche inductive - *niveau 1*
- **CT4.** Rechercher de façon méthodique des pistes de résolutions au problème rencontré - *niveau 1*

Modules spécifiques de la phase 0 :

“Introduction aux méthodes agile” - 7 heures

- Fondamentaux de l'agilité (Scrum, Kanban)
- Structurer les besoins sous forme de User Stories
- Animer les rituels d'équipe (Sprint Planning, Daily Stand-up, Revue et Rétrospective)
- Suivi de l'avancement à l'aide d'outils visuels (Jira, Trello...)
- Documentation itérative

“Préparation FOAD” - 14 heures

- Installation et prise en main des outils de formation à distance en ligne.
- Entraînement par une mise en situation professionnelle

Je découvre le métier visée et mon environnement professionnel de formation

Introduction aux modalités et aux objectifs de la prairie : durée, contenu, rythme, période intensive de découverte du programme de formation et des méthodes d'apprentissage/de formation.

Un atelier de découverte du métier :

- analyse de fiche de poste,
- rencontre avec des professionnels,
- mise en place d'une routine de veille technique et professionnelle pour tout le reste de la formation.

Une première mise en situation professionnelle aborde la configuration des postes de travail et l'initiation aux différents outils professionnels :

- terminal, bash / scripting
- SQL, SGBD

Je prends connaissance et je comprends le référentiel de compétences et le référentiel de certification, avec l'aide du/de la formateur-riche.

Exemple de projet pour la Prairie :

Faire évoluer un script de collecte et d'agrégation de données

Vous êtes alternant data engineer pour le compte d'une petite société de service, spécialisée dans la gestion des données.

Sous la responsabilité de votre tuteur, vous êtes chargé de reprendre un script périodique de collecte et d'agrégation de données issues de différentes bases de données SQL, pour le compte d'un client.

Les évolutions attendues sont répertoriées dans le brief client et font suite à une évolution dans le schéma des données fournies à importer.

Votre mission est la suivante :

- identifier les évolutions dans le schéma de données et les traduire en tâches techniques
- imputer les modifications au script, afin de prendre en compte les évolutions
- tester et valider le fonctionnement du script en environnement de test
- versionner les évolutions
- mettre à jour la documentation technique

Module de contractualisation du parcours avec l'apprenant à Simplon

- La promotion réalise un “arbre de compétence” qui la suivra tout au long de la formation,
- Je rédige mon projet professionnel et mon engagement - ma stratégie - pour l'atteindre,
- Je prends acte de mon rôle d'apprenant à Simplon : projets, learning by teaching, quotidien, veilles...,
- Je signe le règlement intérieur de Simplon.

A la fin de la prairie: [Atelier de sensibilisation à l'usage des IA génératives](#)

Phase 1 - Intervenir sur des ETL et des bases de données les faire évoluer - 70 heures

A la fin de cette phase 1, l'apprenant·e sera capable de par exemple :

- Corriger un bug dans l'exécution d'un script de collecte et d'agrégation de données,
- mettre à jour la procédure d'ETL vers un Datamart,
- piloter et réaliser la mise à jour d'un contrat d'interface,
- créer une base de données Open Data à partir d'un Data Warehouse existant,
- appliquer les obligations réglementaires liées au RGPD dans le cadre du pilotage de la cybersécurité,
- connaître les enjeux environnementaux et sociétaux de l'usage du numérique

Compétences du référentiel visées par la phase 1

- **C4.** Réaliser une veille technique et réglementaire - *niveau 1*
- **C7.** Communiquer tout au long de la réalisation du projet data - *niveau 1*
- **C8.** Automatiser l'extraction de données - *niveau 1 à 2*
- **C9.** Développer des requêtes de type SQL d'extraction des données - *niveau 1 à 2*
- **C10.** Développer des règles d'agrégation de données - *niveau 1 à 2*
- **C11.** Créer une base de données - *niveau 1*

- **CT1.** Planifier le travail à effectuer individuellement et en équipe - *niveau 1 à 2*
- **CT2.** Contribuer au pilotage de l'organisation du travail individuel et collectif - *niveau 1 à 2*
- **CT3.** Définir le périmètre d'un problème rencontré en adoptant une démarche inductive - *niveau 1 à 2*
- **CT4.** Rechercher de façon méthodique des pistes de résolutions au problème rencontré - *niveau 1 à 2*

Modules spécifiques de la phase 1 :

“Obligations réglementaires liées au RGPD” - 4 heures

- Le RGPD dans le cadre du pilotage de la cybersécurité
- Bonnes pratiques de validation de la protection des données aux différentes étapes d'un projet.

“Numérique responsable et IA frugale” - 14 heures

- Connaître les causes de l'impact environnemental du numérique.
- Saisir les enjeux environnementaux et sociétaux
- Connaître les leviers de réduction d'impact : allongement de la durée de vie des appareils, éco-conception, IA frugale.

Activités techniques de la phase 1 :

- Identification des contraintes techniques propres aux sources de données (consulter la documentation, les règles de confidentialité, etc.).
- Reproduction des configurations de l'environnement d'exécution des scripts en environnement de dev/test.
- Mise à jour des extractions de données
 - requêtes HTTP pour la récupération des données depuis un service web (REST).
 - lecture d'un fichier de données dans un script (Python, R, etc.).
 - règles de scraping sur de nouvelles pages web.
 - requêtes d'extraction de type SQL depuis une BDD et un système big data (Hive par exemple)
- Nettoyage et harmonisation :
 - Mise à jour des règles de filtrages/parsing des données utiles dans les résultats obtenus depuis :
 - une API,
 - depuis la lecture d'un ou de plusieurs fichiers de données,
 - et depuis l'HTML collecté d'un site web (scraping).
 - Mise à jour des règles d'agrégation des données collectées depuis chaque source en un jeu de données brutes unique.
 - Mise à jour de l'identification des entrées corrompues dans le jeu de données (par exemple, données partielles et/ou manquantes) et de la suppression des entrées corrompues.
 - Mise à jour de l'identification des entrées au format non normalisé.
 - Mise à jour de la l'homogénéisation des formats de données (par exemple, format des dates, des unités, etc.).
- Versionnement des évolutions avec Git et un dépôt Git en ligne.
- Prise de connaissance de la modélisation de la structure des données de la base de données selon la méthode MERISE.
- Prise en main du système de gestion de base de données.
- Reproduction de la configuration de la base de données dans le système de gestion de base de données en environnement de dev/test.
- Mise à jour du script d'import des données en base de données.

Activités transversales de la phase 1 :

- Organisation d'une veille professionnelle : routine, outils, synthèse, communication.
- Rédaction des spécifications techniques pour les évolutions souhaitées.
- Arbitrage et résolution des problèmes bloquant tout au long de la réalisation du projet.
- Suivi des indicateurs d'avancement.
- Communication des résultats et des livrables.
- Accompagnement à la prise en main des outils et services data livrés.
- Mise à jour des documentations techniques (scripts, procédures, etc).
- Mise à jour du registre des traitements et des procédures de tri de données personnelles en vue de la mise en conformité de la base de données avec le RGPD.

Exemples de sujets pour la veille tout au long de la phase 1 :

- Git et versionnement des sources
- RGPD
- Merise

Exemple de stacks techniques pour les activités de la phase 1 :

- SQL
- PostgreSQL
- Python
- Talend
- DBT

Exemples de situation d'apprentissage pour la phase 1 :

Corriger un bug dans l'exécution d'un script de collecte et d'agrégation de données

Vous êtes alternant data engineer pour le compte d'une petite société de service, spécialisée dans la gestion des données.

Sous la responsabilité de votre tuteur, vous êtes chargé de corriger un bug identifié dans l'exécution du même script périodique de collecte et d'agrégation de données issues de plusieurs bases de données SQL, pour le compte d'un client.

Vous avez accès au ticket et aux journaux d'erreur.

Votre mission est la suivante :

- analyser les journaux d'erreur et identifier la nature du problème technique
- identifier la cause de l'erreur dans l'exécution du script
- rechercher une solution pour la corriger
- tester et valider la solution
- versionner le correctif
- mettre à jour la documentation technique

Mettre à jour la procédure d'ETL vers un Datamart

Vous travaillez en tant que data engineer junior pour le compte d'un grand groupe.

Le schéma du datamart dédié aux ventes est amené à évoluer. Cela implique notamment la mise à jour de la procédure d'ETL à destination de ce datamart.

Vous êtes chargé de réaliser cette mise à jour sur la base des éléments d'évolution du schéma et de la documentation technique du système en l'état.

Votre mission est la suivante :

- Prendre connaissance des évolutions dans le schéma de données du datamart
- Identifier les évolutions nécessaires à implémenter dans la procédure ETL afin de prendre en compte les évolutions du schéma de données.
- Communiquer la mise à jour de l'ETL et ses éventuelles implications aux utilisateurs des données concernées.

Piloter et réaliser la mise à jour d'un contrat d'interface

Vous travaillez en tant que data engineer junior pour le compte d'une ESN. Vous êtes en mission pour une grande entreprise de l'industrie du luxe.

L'équipe produits a changé la structuration de sa gamme en ajoutant un niveau "sous-famille" qui permet d'avoir une vision plus fine de leurs performances. Ils souhaitent que ce champ soit mis à disposition dans les tables sur lesquelles s'appuient leurs tableaux de bord.

Vous êtes chargé de mettre à jour les contrats d'interface et d'ajuster les ETLs en conséquence.

Votre mission est la suivante :

- Analyser la demande métier
 - prendre connaissance des changements induits dans le modèle de données
 - identifier les tables concernées
 - identifier les tableaux de bord concernés
- Planifier la réalisation du projet data
 - Identifier les interlocuteurs pertinents
- Modifier le flux de données suite au changement
 - Modifier le contrat d'interface
 - Tester les requêtes SQL dépendant du contrat d'interface et les modifier si besoin
 - Tester, déployer, livrer
- Communiquer sur la livraison
- Mettre à jour la documentation

Créer une base de données *Open Data* à partir d'un *Data Warehouse* existant

Vous travaillez en tant que data engineer junior pour le compte d'un grand groupe, qui dispose de données à l'échelle nationale, et dans lequel le flux de données est déjà en place.

Cette année, l'un des objectifs de l'entreprise consiste à mettre des données à disposition en *Open Data*.

Vous êtes chargé de préparer la base de données qui sera exposée en *Open Data*.

Votre mission est la suivante :

- Réaliser une veille technique et réglementaire sur les différentes contraintes associées à l'*Open Data* :
 - données personnelles
 - sécurité
 - secret statistique
- Modéliser la base de données qui sera exposée en *Open Data*
 - le schéma cible
 - les relations avec le *Data Warehouse* existant

- Créer la base *Open Data*
- Implémenter les requêtes d'extraction et d'agrégation pour alimenter la base *Open Data*
- Partager la base *Open Data*

Phase 2 - Intervenir sur un data warehouse et le faire évoluer - 98 heures

A la fin de cette phase 2, l'apprenant·e sera capable de par exemple :

- Intégrer de nouveaux jeux de données à un data warehouse,
- ajouter un nouveau pays dans un data warehouse,
- gérer la saturation d'un datawarehouse,
- s'approprier les principes fondateurs de la République,
- appliquer les techniques de communication de la relation usager et client.

Compétences du référentiel visées par la phase 2

- **C4.** Réaliser une veille technique et réglementaire - *niveau 1 à 2*
- **C7.** Communiquer tout au long de la réalisation du projet data - *niveau 1 à 2*
- **C13.** Modéliser la structure des données d'un entrepôt de données - *niveau 1 à 2*
- **C14.** Créer un entrepôt de données - *niveau 1 à 2*
- **C15.** Intégrer les ETL nécessaires en entrée et en sortie d'un entrepôt de données - *niveau 1 à 2*
- **C16.** Gérer l'entrepôt de données - *niveau 1 à 2*
- **C17.** Implémenter des variations dans les dimensions de l'entrepôt de données - *niveau 1 à 3*

Modules spécifiques de la phase 2 :

“Laïcité, citoyenneté, valeurs de la république” - 4 heures

- Histoire et principes fondateurs de la République
- Droits de l'Homme
- Éléments d'histoire de la laïcité en France
- Sens et enjeux de la laïcité

“Relation usager et client” - 4 heures

- ITIL.
- Appliquer une procédure de questionnement.
- Appliquer une procédure de communication de crise.
- Accompagnement, sensibilisation et formation des usagers sur des questions clés : sécurité, productivité, etc.

Activités techniques de la phase 2 :

- Explicitation des données attendues selon le besoin d'analyse.
- Prise de connaissance des schémas des structures de données en faits et dimensions du data warehouse.
- Reproduction de la configuration du data warehouse en environnement de dev/test.
- Test du bon fonctionnement de l'entrepôt de données en environnement de dev/test.
- Identification des formats et du volume des sources de données.
- Intégration des nouvelles sources en adaptant les ETL déjà en place.
- Qualification des variations à intégrer.
- Intégration des variations à l'entrepôt de données et aux ETL.

Activités transversales de la phase 2 :

- Organisation d'une veille professionnelle : routine, outils, synthèse, communication.
- Mise à jour des spécifications techniques pour les évolutions attendues.
- Animation des échanges entre les membres de l'équipe technique en charge de la réalisation du projet.
- Arbitrage et résolution des problèmes bloquants tout au long de la réalisation du projet.
- Suivi des indicateurs d'avancement.
- Communication des résultats et des livrables.
- Accompagnement à la prise en main des outils et services data livrés.
- Participation à l'activité de maintenance de l'entrepôt de données : debug, tickets, etc.
- Suivi de l'activité de maintenance : indicateurs de service en fonction des SLA à l'aide d'un tableau de bord.
- Mise à jour des documentations techniques (scripts, procédures, accès et droits, etc).
- Mise à jour du registre des traitements et des procédures de tri de données personnelles en vue de la mise en conformité de la base de données avec le RGPD.

Exemples de sujets pour la veille tout au long de la phase 2 :

- Forme normale, normalisation
- Les deux types d'architecture d'un data warehouse : top-down et bottom-up
- ETL & ELT
- Modélisation de données : étoile, flocon, etc.
- OLAP, OLTP
- Cubes et hypercubes multidimensionnels

Exemple de stacks techniques pour les activités de la phase 2 :

- Extraction - Transformation - Load :
 - SQL
 - python
- SGBD et environnements :

- PostgreSQL

Exemple de situation d'apprentissage pour la phase 2 :

Intégrer de nouveaux jeux de données à un data warehouse

Vous intervenez comme consultant en data engineering pour accompagner une moyenne entreprise de commerce de gros à faire évoluer la gestion de ses données.

Depuis deux ans, les données issues des différents SI métier (logistique, service client et marketing, finance....) ont été centralisées dans un *data lake* alimentant un *datawarehouse*. Ils souhaitent aujourd'hui intégrer au datawarehouse les données générées par les capteurs en entrepôt, qui sont volumineuses et non structurées. L'intégration des données massives est une nouveauté pour votre agence de consulting.

On vous confie le brief client, des documents de pilotage issus de précédentes missions de votre agence de consulting et un échantillon des données issues des capteurs. Vous êtes chargé de cadrer le projet d'intégration au datawarehouse des données générées par les capteurs.

Votre mission est la suivante :

- Intégrer les thématiques suivantes dans le système de veille technologique :
 - IoT
 - Systèmes de Gestion de Bases de Données Massives
- Proposer et sélectionner une solution technique comprenant :
 - les ajustements à apporter aux outils existants
 - les outils complémentaires à intégrer
 - le résultat prévu
- Présenter au client la proposition, et intégrer ses retours
- Implémenter l'ingestion des données non structurées dans le data warehouse existant
- Documenter, tester, livrer

Ajouter un nouveau pays dans un data warehouse

Vous travaillez en tant que data engineer pour le compte d'une multinationale chez qui la centralisation des données est déjà finalisée pour l'activité française.

La prochaine étape consiste à intégrer les données d'un autre pays. Ce projet avait été confié à votre responsable, cependant suite à la démission de dernier, le projet a pris du retard.

Vous êtes chargé de prendre le relais de votre manager sur l'ajout des données d'un nouveau pays dans les bases de données.

Votre mission est la suivante :

- Réaliser un rapide état des lieux du projet : parties prenantes, planification, organisation, feuille de route initiale, statut des différents livrables
- Estimer les différences entre les données du nouveau pays et les données déjà présentes
- Adaptations éventuelles des ETLs exploitant ces sources
- Test, documentation, livraison

Phase 3 - Intervenir sur un data lake et le faire évoluer - 133 heures

A la fin de cette phase 3, l'apprenant·e sera capable de par exemple :

- Connecter un data lake existant à de nouvelles sources de données en respectant le RGPD,
- augmenter une nouvelle fois la capacité de stockage du data lake,
- paramétrer les accès au data lake pour une équipe qui en fait la demande.

Compétences du référentiel visées par la phase 3

- **C4.** Réaliser une veille technique et réglementaire - *niveau 2*
- **C5.** Planifier la réalisation d'un projet data - *niveau 1*
- **C6.** Superviser la réalisation d'un projet data - *niveau 1*
- **C7.** Communiquer tout au long de la réalisation du projet data - *niveau 2*
- **C18.** Concevoir l'architecture du data lake - *niveau 1*
- **C19.** Intégrer les différents composants d'infrastructure du data lake - *niveau 1*
- **C20.** Gérer le catalogue des données - *niveau 1*
- **C21.** Implémenter les règles de gouvernance des données - *niveau 1*

Activités techniques de la phase 3 :

- Prise en main des outils batch nécessaire à la collecte et l'alimentation en données
- Prise en main des outils streaming d'acquisition nécessaire à la collecte et l'alimentation en données
- Prise en main de l'outil de catalogue de données
- Reproduction des configurations du data lake en environnement de dev/test
- Reproduction des configuration des outils batch et temps réel.
- Installation de l'outil de catalogue de données en suivant une procédure.
- Adaptation des procédures d'alimentation automatisées selon les évolutions attendues.
- Programmation des procédures de suppression automatique liées au cycle de vie.
- Reproduction du paramétrage des droits pour la recherche sur l'index des données rajoutées suite à l'évolution implémentée selon les spécifications données.

Activités transversales de la phase 3 :

- Organisation d'une veille professionnelle : routine, outils, synthèse, communication.
- Rédaction des spécifications techniques pour les évolutions attendues.
- Organisation du pilotage de la réalisation technique (kanban, scrum, gantt...).
- Priorisation et répartition des tâches.
- Planification de la réalisation des tâches (Scrum board, Kanban, etc.).

- Communication des éléments de planification (feuille de route et planification de la production).
- Animation des échanges entre les membres de l'équipe technique en charge de la réalisation du projet.
- Arbitrage et résolution des problèmes bloquant tout au long de la réalisation du projet.
- Suivi des indicateurs d'avancement.
- Communication des résultats et des livrables.
- Accompagnement à la prise en main des outils et services data livrés.
- Mise à jour des documentations techniques (scripts, procédures, accès et droits, etc).
- Mise à jour du registre des traitements et des procédures de tri de données personnelles en vue de la mise en conformité de la base de données avec le RGPD.

Modalités liées aux activités de pilotage :

Concernant les activités de pilotage, un système de rotation du rôle de pilote (ou lead technique) sera mis en place.

Par exemple, en mettant les apprenants par binôme permettrait de donner le rôle de pilote d'équipe à tou·te·s les apprenant·es en seulement deux cycle. A contrario, des équipes plus nombreuses demandent un nombre de cycles plus grand.

Sinon, il est possible de réaliser cette rotation en différenciant la progression pédagogique tout au long du parcours, c'est à dire en assignant les missions de pilotages à des apprenant·es différent·es à chaque situation d'apprentissage. Ce qui implique une progression différentes sur les compétences de pilotage en fonction de l'assignation de ce rôle dans le temps pour chaque apprenant·e.

Exemples de sujets pour la veille tout au long de la phase 3 :

- NoSQL
- data lake, lake house et data swamp

Exemple de stacks techniques pour les activités de la phase 3 :

- Languages:
 - Bash
 - Spark (PySpark, ScalaSpark)
- Plateforme :
 - MS (Azure Data Lake Storage, Azure Blob),
 - AWS (S3, Lake Formation)
 - GCP (GCS, BigLake, BigTable)
- Open source :
 - HDFS
 - MongoDB
 - PostgreSQL
 - MariaDB
 - Elasticsearch
 - Apache Hive
- Orchestration, conteneurisation :
 - Docker

- Kubernetes
- Airflow
- Dagster
- Streaming
 - Flume, Kafka

Exemples de situation d'apprentissage pour la phase 3 :

Connecter un data lake existant à de nouvelles sources de données en respectant le RGPD

Vous êtes alternant data engineer pour le compte d'une petite société de service, spécialisée dans la gestion des données.

Sous la responsabilité de votre tuteur, vous êtes chargé de connecter le data lake en cours de développement à de nouvelles sources de données, dont certaines contiennent des données personnelles.

Vous avez accès à la feuille de route du projet, aux connecteurs précédemment implémentés, et aux sources des données à intégrer.

Votre mission est la suivante :

- proposer une feuille de route pour intégrer les nouvelles sources données conformes au RGPD
 - faire un état des lieux des contraintes RGPD liées aux nouvelles sources à intégrer
 - proposer au client un traitement pour sources de données non conformes
 - choisir les sources de données à intégrer en l'état
 - ajouter les actions de mise en conformité à la feuille de route du projet
- intégrer les nouvelles sources
 - diagnostiquer les nouvelles sources (nature, impact sur la volumétrie)
 - reproduire l'implémentation du connecteur le plus adapté aux caractéristiques des nouvelles sources de données
 - programmer la suppression automatique liée au cycle de vie
 - paramétrer les droits d'accès aux nouvelles données
 - tester et valider les connecteurs
- versionner la modification
- mettre à jour la documentation (technique, catalogue de données, registre du traitement de données personnelles)
- intégrer au système de veille de l'entreprise la réglementation sur la gestion des données à caractère personnel (RGPD)

Augmenter une nouvelle fois la capacité de stockage du *data lake*

Vous travaillez en tant que data engineer junior pour le compte d'un grand groupe.

De nouvelles sources de données ont été ajoutées, à tel point que le *data lake* a atteint 80% de sa capacité. Cela implique d'en augmenter la capacité. Le même ajustement a été réalisé l'an dernier par un membre de votre équipe.

Vous êtes chargé de réaliser cet ajustement sur la base de la procédure réalisée l'an dernier.

Votre mission est la suivante :

- Prendre connaissance :

- de la procédure précédente
 - des informations relatives à la taille actuelle et prévisionnelle du *data lake*
- Estimer les impacts en termes de coûts, ainsi que les risques, de l'augmentation de la taille du *data lake*
- Organiser la prise de décision et l'arbitrage concernant le choix d'augmentation de la taille du *data lake*
- Obtenir les accords et validations nécessaires
- Reproduire la procédure précédente de variation de taille du *data lake* en l'adaptant au besoin actuel
- Communiquer et diffuser l'information
- Mettre à jour la documentation technique

Paramétrer les accès au *data lake* pour une équipe qui en fait la demande

Vous travaillez en tant que data engineer junior pour le compte d'une entreprise du numérique.

L'équipe RH intègre de plus en plus la donnée dans son activité et à ce titre souhaite pouvoir accéder directement au *data lake* afin d'avoir une meilleure compréhension des données exploitables pour leurs applications métier. Cela implique de leur accorder des accès appropriés. Vous êtes chargé de configurer leurs accès.

Votre mission est la suivante :

- Prendre connaissance des différents types d'accès et groupes préexistants, et évaluer l'opportunité d'en créer de nouveaux
- Prendre connaissance du besoin de l'équipe demandeuse et des usages qu'elle prévoit
- Valider la légitimité de cette demande auprès de l'équipe en charge de la gouvernance data
- Sélectionner le groupe et le type de droit correspondant au besoin
- Créer les accès correspondant
- Vérifier que les accès fournis
 - répondent au besoin de l'équipe RH
 - sont conformes à la réglementation (RGPD)
- Documenter la création de nouveaux accès

Répliquer la mise en place d'un *data lake* pour un autre client

Vous êtes alternant data engineer pour le compte d'une petite société de service, spécialisée dans la gestion des données.

Votre client, une PME de 200 salariés, souhaite professionnaliser l'exploitation de ses données actuellement réalisée dans des tableurs individuels. Pour cela, il est fait appel à l'ESN dans laquelle vous travaillez afin de mettre en place un *data lake*.

C'est une mission qui a déjà été réalisée par votre ESN pour d'autres clients du même type. En vous inspirant de ce qui a été fait pour les autres clients, vous êtes chargé de concevoir et de créer l'architecture du *data lake* répondant à ce besoin.

Votre mission est la suivante :

- Proposer un document de cadrage à l'image des cadrages des projets précédents, il doit comprendre :
 - le schéma de l'architecture du data lake
 - une synthèse du besoin du client : type et taille de sources données, modèle de données, usages prévus
 - les contraintes techniques et budgétaires du projet,
- Proposer une solution technique à partir des exemples des clients précédents :
 - Sélectionner le système compatible avec l'infrastructure et la politique IT de l'organisation
 - Argumenter et chiffrer le choix des outils sélectionnés
- Proposer un pilotage projet comprenant :
 - l'équipe projet
 - une roadmap
 - les indicateurs de suivi
 - une organisation Kanban à l'image de celle du projet client précédent
- Créer le data lake à partir de l'implémentation du précédent client
- Prévoir les outils pour la collecte et l'alimentation en données :
 - des outils batch (flux ponctuels)
 - des outils streaming (flux continus)
 - de l'outil de catalogage de données adapté au modèle de données et à l'infrastructure du data lake
- Présenter au client la proposition, et intégrer ses retours

Phase 4 - Concevoir et créer des ETL, des bases de données et la mise à disposition des données aux équipes d'analyse - 98 heures

A la fin de cette phase 4, l'apprenant·e sera capable de par exemple :

- Transposer des analyses et/ou visualisations dans une nouvelle plateforme cloud,
- créer de nouveaux flux de données pour une nouvelle demande métier.

Compétences du référentiel visées par la phase 4

- **C1.** Analyser l'expression d'un besoin de projet data - *niveau 1*
- **C2.** Cartographier les données disponibles - *niveau 1*
- **C3.** Concevoir un cadre technique d'exploitation des données - *niveau 1*
- **C4.** Réaliser une veille technique et réglementaire - *niveau 2 à 3*
- **C5.** Planifier la réalisation d'un projet data - *niveau 1*
- **C7.** Communiquer tout au long de la réalisation du projet data - *niveau 2 à 3*
- **C8.** Automatiser l'extraction de données- *niveau 2*
- **C9.** Développer des requêtes de type SQL* d'extraction des données - *niveau 2*
- **C10.** Développer des règles d'agrégation de données issues de différentes sources - *niveau 2*
- **C11.** Créer une base de données - *niveau 2*
- **C12.** Partager le jeu de données en configurant des interfaces logicielles et en créant des interfaces programmables - *niveau 2*

Activités techniques de la phase 4 :

- Identification des contraintes techniques propres aux sources de données (consulter la documentation, les règles de confidentialité, etc.).
- A partir d'un exemple de topographie pour un projet de même nature et d'un guide méthodologique :
 - Inventaire des sources (applications, IoT, ventes, etc.) et des domaines de données utiles au projet data.
 - Inventaire des gestionnaires ou responsables des différents domaines (clients, produits, fournisseurs.
 - Inventaire des données et métadonnées nécessaires au projet et déjà disponibles, et de leurs structures.
 - Inventaire des modalités d'accès, d'autorisation ou encore d'interconnection logiciel aux sources de données identifiées.
 - Identification des données manquantes pour le projet data.
 - Qualification des flux de données : fréquence et volume des flux.
 - Qualification des composants du système d'information existants impliqués dans le cadre technique d'exploitation des données envisagé.

- Formalisation d'une topographie des données
- Construction des requêtes HTTP pour la récupération des données depuis un service web (REST).
- Lecture d'un fichier de données dans un script (Python, R, etc.).
- Téléchargement de l'HTML d'une ou plusieurs pages web visées par une action de scraping.
- Connexion programmatique (Python, R, etc.) à un système de gestion de base de données et à un système big data (Hive, Apache Impala, etc.).
- Exécution programmatique des requêtes d'extraction de type SQL.
- Écriture des requêtes d'extraction de type SQL de récupération de données stockées en base de données et depuis un système big data (Hive, Spark, etc.).
- Programmation des filtrages/parsing des données utiles dans les résultats obtenus depuis :
 - une API,
 - depuis la lecture d'un ou de plusieurs fichiers de données,
 - et depuis l'HTML collecté d'un site web (scraping).
- Programmation des règles d'agrégation des données collectées depuis chaque source en un jeu de données brutes unique.
- Programmation de l'identification des entrées corrompues dans le jeu de données (par exemple, données partielles et/ou manquantes).
- Programmation de la suppression des entrées corrompues.
- Programmation de l'identification des entrées au format non normalisé.
- Programmation de la l'homogénéisation des formats de données (par exemple, format des dates, des unités, etc.).
- Versionnement des scripts avec Git et un dépôt Git en ligne.
- Modélisation de la structure des données de la base de données selon la méthode MERISE*.
- Choix du système de gestion de base de données.
- Création de la base de données dans le système de gestion de base de données.
- Programmation du script d'import des données en base de données.
- Développement des points de terminaison de l'API REST exposant les données stockées en base.
- Développement des règles d'autorisation et d'accès aux points de terminaison de l'API REST.
- Configuration des accès à la base de données.

Activités transversales de la phase 4 :

- Analyse du besoin exprimé, selon le formalisme de l'acheteur : DCE, brief interne, clauses d'un contrat privé, etc. en suivant un exemple de même nature.
- Questionnement de l'expression de besoin à l'aide d'un guide, et notamment sur les aspects : objectifs du projet, périmètre fonctionnel du projet, moyens humains, techniques et financiers mobilisables.
 - Identification de tous les métiers concernés par le périmètre du projet data suivant : sources et génération des données, collecte et stockage des données, exploitation et analyse des données.
 - Audition des usagers potentiels du projet data pour compléter l'expression du besoin sur les aspects précis d'analyse et d'exploitation des données du projet data
 - Anticipation de l'effort nécessaire et des éventuels freins à lever pour la mise en conformité du projet avec le RGPD, au regard de l'expression de besoin.

- Inventaire des éventuels besoins spécifiques auprès des futurs usagers du projet data.
 - Anticipation de l'effort d'accessibilité à mettre en oeuvre tout au long du projet
- Conclure sur une recommandation de cadrage du projet data en suivant un modèle de rédaction de préconisations.
- Communiquer le cadrage du projet data au(x) commanditaire(s).
- Organisation d'une veille professionnelle : routine, outils, synthèse, communication.
- Rédaction des spécifications techniques.
- Définition des processus de mise en conformité avec le RGPD.
- Définition de la stratégie d'éco-responsabilité sur l'activité data
- Organisation du pilotage de la réalisation technique (kanban, scrum, gantt...).
- Priorisation et répartition des tâches.
- Planification de la réalisation des tâches (Scrum board, Kanban, etc.).
- Communication des éléments de planification (feuille de route et planification de la production).
- Animation des échanges entre les membres de l'équipe technique en charge de la réalisation du projet.
- Arbitrage et résolution des problèmes bloquant tout au long de la réalisation du projet.
- Suivi des indicateurs d'avancement.
- Communication des résultats et des livrables.
- Accompagnement à la prise en main des outils et services data livrés.
- Rédaction des spécifications techniques.
- Documentation technique.
- Mise en conformité RGPD.

Exemples de sujets pour la veille tout au long de la phase 4 :

- API REST avec Python (FastAPI, Flask...)

Exemple de stacks techniques pour les activités de la phase 4 :

- Bash
- Docker
- SQL, Hive, HDFS
- Python, FastAPI
- PostgreSQL
- Talend

Exemples de situations d'apprentissage pour la phase 4 :

Transposer des analyses et/ou visualisations dans une nouvelle plateforme cloud

Vous êtes alternant data engineer pour le compte d'une ESN spécialisée dans la gestion des données. Vous êtes positionné sur une mission pour un laboratoire de cosmétiques qui commercialise directement ses produits, dans plusieurs pays. Il dispose de données concernant ses produits, ses clients et ses ventes en magasin et sur son site de e-commerce historiquement conservées dans des SI distincts. Un nouveau data lake centralisant toutes ces données vient d'être livré et un datawarehouse dans lequel ces données sont nettoyées et mises en forme a

également été mis en place. Cependant les métiers continuent d'utiliser les tables et visualisations connectées aux anciens SI.

Le laboratoire vous confie le schéma de son ancienne architecture de données et la description de sa nouvelle architecture, un accès aux tables et leurs visualisations connectées à l'ancien SI, ainsi qu'une transcription de deux intervenants métier sur leur utilisation de leurs visualisations.

Votre mission est la suivante :

- Synthétiser le cadre technique de votre intervention
 - Résumer les spécifications des visualisations utilisés par les métiers et de leurs usages
 - Représenter les changements dans le schéma de données vers le nouveau data lake
 - Définir et argumenter les services et outils que vous allez utiliser pour créer ces nouvelles visualisations
- Rédiger les scripts nécessaires à l'extraction et l'agrégation des analyses et/ou des visualisations
- Connecter les interfaces utilisateurs aux nouvelles tables que vous avez créées
- Documenter, tester
- Communiquer la solution aux utilisateurs

Créer des nouveaux flux de données pour une nouvelle demande métier

Vous êtes data engineer au sein de l'équipe Data du Groupe La Poste. On vous confie une mission d'ingénierie pour un client interne : l'équipe Support Utilisateur.

L'équipe Support Utilisateurs souhaite exploiter une nouvelle source de données qui vient d'être mise à disposition dans le data lake : les enregistrements des automates en bureau de poste. L'objectif est d'analyser les pannes, les bugs ainsi que les difficultés les plus fréquentes rencontrées par les utilisateurs des automates. Ce sont des données volumineuses et non structurées, contrairement à ce que manipule habituellement l'équipe support.

Votre mission est la suivante :

- Cadrer le projet :
 - Résumer le besoins de l'équipe Support Utilisateur
 - Estimer la nature et la taille des données à manipuler
 - Dresser le bilan des ressources et des contraintes en présence
 - Proposer une solution technique à partir d'une veille réglementaire et technique
 - Définir des jalons, des indicateurs d'avancement, et des moyens de suivi pas l'équipe Support Utilisateur
- Organiser les temps d'échange avec les parties prenantes
- Dimensionner et créer la base de données d'accueil des données nettoyées
- Rédiger les scripts d'extraction, de nettoyage, de transformation et d'agrégation des données issues des automates
- Tester, documenter et livrer le projet
- Communiquer tout au long du projet avec les parties prenantes

Phase 5 - Concevoir et créer un data warehouse - 105 heures

A la fin de cette phase 5, l'apprenant·e sera capable de par exemple :

- Concevoir un data warehouse à partir de la cartographie des données de l'organisation,
- améliorer la qualité de données issues d'un flux de traitement existant,
- organiser et mettre en oeuvre la migration de données depuis une solution On Premise vers le Cloud,
- acquérir les bonnes pratiques et les techniques de recherche d'emploi

Compétences du référentiel visées par la phase 5

- **C1.** Analyser l'expression d'un besoin de projet data - *niveau 2*
- **C2.** Cartographier les données disponibles - *niveau 2*
- **C3.** Concevoir un cadre technique d'exploitation des données - *niveau 2*
- **C4.** Réaliser une veille technique et réglementaire - *niveau 3*
- **C5.** Planifier la réalisation d'un projet data - *niveau 1 à 2*
- **C6.** Superviser la réalisation d'un projet data - *niveau 1*
- **C7.** Communiquer tout au long de la réalisation du projet data - *niveau 3*

- **C13.** Modéliser la structure des données d'un entrepôt de données - *niveau 2 à 3*
- **C14.** Créer un entrepôt de données - *niveau 2 à 3*
- **C15.** Intégrer les ETL nécessaires en entrée et en sortie d'un entrepôt de données - *niveau 2 à 3*
- **C16.** Gérer l'entrepôt de données - *niveau 2*

Module spécifique de la phase 5 :

“Atelier Technique de Retour à l'Emploi (TRE)” - 21 heures

- Atelier candidature : bonnes pratiques pour un CV et une lettre de motivation
- Atelier recherche d'emploi et outils : Job Teaser LinkedIn, Nos Talents Nos Emplois, etc.
- Atelier entretien d'embauche avec simulations d'entretien

Activités techniques de la phase 5 :

- Identification des contraintes techniques propres aux sources de données (consulter la documentation, les règles de confidentialité, etc.).
- Inventaire des sources (applications, IoT, ventes, etc.) et des domaines de données utiles au projet data.
- Inventaire des gestionnaires ou responsables des différents domaines (clients, produits, fournisseurs).
- Inventaire des données et métadonnées nécessaires au projet et déjà disponibles, et de leurs structures.

- Inventaire des modalités d'accès, d'autorisation ou encore d'interconnection logiciel aux sources de données identifiées.
- Identification des données manquantes pour le projet data.
- Qualification des flux de données : fréquence et volume des flux.
- Qualification des composants du système d'information existants impliqués dans le cadre technique d'exploitation des données envisagé.
- Formalisation d'une topographie des données
- Qualification des données attendues selon le besoin d'analyse.
- Production des schémas des structures de données en faits* et dimensions* selon les besoins d'analyse.
- Définition des relations entre les faits et les dimensions dans les schémas de conception.
- Configuration des outils.
- Configuration des data marts*.
- Configuration des accès.
- Test du bon fonctionnement de l'entrepôt de données.
- Identification des formats et du volume des sources de données,
- Intégration des sources,
- Identification des formats des zones de sortie,
- Configuration des sorties,
- Intégration des règles de transformation et de traitement nécessaires ; par exemple : passage de table-relations à faits-dimensions.
- Maintenance en condition opérationnelle des outils et composants techniques de l'entrepôt de données
- Intégration des évolutions de l'entrepôt de données : ajout datamart, scalabilité, etc.
- Gestion des évolutions des accès à l'entrepôt de données et des accès aux données opérationnelles sources.

Activités transversales de la phase 5 :

- Analyse du besoin exprimé, selon le formalisme de l'acheteur : DCE, brief interne, clauses d'un contrat privé, etc. en suivant un exemple de même nature.
- Questionnement de l'expression de besoin à l'aide d'un guide, et notamment sur les aspects : objectifs du projet, périmètre fonctionnel du projet, moyens humains, techniques et financiers mobilisables.
 - Identification de tous les métiers concernés par le périmètre du projet data suivant : sources et génération des données, collecte et stockage des données, exploitation et analyse des données.
 - Audition des usagers potentiels du projet data pour compléter l'expression du besoin sur les aspects précis d'analyse et d'exploitation des données du projet data
 - Anticipation de l'effort nécessaire et des éventuels freins à lever pour la mise en conformité du projet avec le RGPD, au regard de l'expression de besoin.
 - Inventaire des éventuels besoins spécifiques auprès des futurs usagers du projet data.
 - Anticipation de l'effort d'accessibilité à mettre en oeuvre tout au long du projet
- Conclure sur une recommandation de cadrage du projet data en suivant un modèle de rédaction de préconisations.
- Communiquer le cadrage du projet data au(x) commanditaire(s).

- Organisation d'une veille professionnelle : routine, outils, synthèse, communication.
- Rédaction des spécifications techniques.
- Définition des processus de mise en conformité avec le RGPD.
- Définition de la stratégie d'éco-responsabilité sur l'activité data
- Organisation du pilotage de la réalisation technique (kanban, scrum, gantt...).
- Priorisation et répartition des tâches.
- Planification de la réalisation des tâches (Scrum board, Kanban, etc.).
- Communication des éléments de planification (feuille de route et planification de la production).
- Animation des échanges entre les membres de l'équipe technique en charge de la réalisation du projet.
- Arbitrage et résolution des problèmes bloquant tout au long de la réalisation du projet.
- Suivi des indicateurs d'avancement.
- Organisation de l'activité de maintenance de l'entrepôt de données : répartition des tâches et priorisation.
- Suivi de l'activité de maintenance : indicateurs de service en fonction des SLA* à l'aide d'un tableau de bord.
- Communication des résultats et des livrables.
- Accompagnement à la prise en main des outils et services data livrés.
- Rédaction des spécifications techniques.
- Documentation technique.
- Mise en conformité RGPD.

Exemples de sujets pour la veille tout au long de la phase 5 :

- Architecture lakehouse

Exemple de stacks techniques pour les activités de la phase 5 :

- Bash
- Docker
- SQL
- Talend
- PostgreSQL / Apache Hive

Exemples de situation d'apprentissage pour la phase 5 :

Concevoir un data warehouse à partir de la cartographie des données de l'organisation

Vous êtes data engineer junior pour une ESN spécialisée dans la gestion des données, qui a pour client une préfecture.

Le département technique de la préfecture a rassemblé un grand nombre de données issues de différentes sources : fichiers fournis par les acteurs économiques, données non structurées fournies par des objets connectés, open data issues de *datagouv*.... Cette base est certes très riche, mais peu maniable et difficile d'accès.

La préfecture souhaite réaliser un data hub pour rendre ces données accessibles aux différents profils d'utilisateurs potentiels, elle met en concurrence plusieurs entreprises, et vous demande une conception détaillée accompagnée d'un premier chiffrage.

Votre mission est la suivante :

- Mener l'analyse et le cadrage projet :
 - Recenser et décrire les besoins et les cas d'usage auxquels devra répondre le datawarehouse : reporting, études et analyses, applicatifs....
 - Cartographier les données disponibles : schéma, qualité, contraintes réglementaires
 - Dresser le bilan des contraintes et des ressources associées au projet
 - Réaliser une veille aboutissant à une ou plusieurs propositions d'outillage technique répondant à la fois aux besoins et aux contraintes
- Concevoir une réponse technique adaptée
- Livrer votre conception
- Planifier la réalisation du data *hub* :
 - identifier l'équipe projet,
 - définir un calendrier prévisionnel et un premier chiffrage,
 - définir un pilotage de projet, avec des réunions client et des outils de suivi
- Présenter votre conception et défendre votre projet pour remporter le marché !

Améliorer la qualité de données issues d'un flux de traitement existant

Vous êtes data engineer junior pour Fit&Fun, un réseau de salles de sport présent en Europe.

Depuis cinq ans, Fit&Fun collecte un grand nombre de données concernant la fréquentation de ses salles de sport et de son site internet. Ces données sont rassemblées dans un data lake et mises à disposition dans un datawarehouse.

De nombreux problèmes de qualité de données sont récemment apparus : données manquantes, corrompues, aberrantes, dupliquées, non-traçables.... Fit&Fun fait appel à vous pour mettre en place un meilleur processus qualité.

Votre mission est la suivante :

- Cadrer le projet :
 - Modéliser le datawarehouse
 - Prendre connaissance des principaux problèmes de qualité de données
- Mener une veille technique et réglementaire sur la gouvernance des données par le monitoring et l'orchestration
- Concevoir une solution technique et opérationnelle comprenant :
 - la démarche DataOps à mettre en place au sein de l'équipe Data
 - le monitoring de la chaîne de transformation de la donnée
 - l'orchestration de la chaîne de transformation de la donnée avec un outil type Airflow
- Présenter votre proposition et prendre en compte les retours client
- Implémenter votre solution de monitoring et d'orchestration de la chaîne de transformation de la donnée
- Documenter

Organiser et mettre en oeuvre la migration de données depuis une solution On Premise vers le Cloud

Vous êtes alternant data engineer pour le compte d'une ESN spécialisée dans la gestion des données. Vous êtes positionné sur une mission pour un laboratoire de cosmétiques qui commercialise directement ses produits, dans plusieurs pays. Il dispose de données concernant ses produits, ses clients et ses ventes en magasin et sur son site de e-commerce. Le data lake centralisant toutes ces données, historiquement conservées dans des SI distincts, vient d'être livré. Cette base est certes très riche, mais peu maniable et difficile d'accès.

Le laboratoire fait appel à vous pour réaliser un datawarehouse qui permettrait de rendre ces données accessibles aux différents profils d'utilisateurs. Il vous donne accès à son data lake et vous partage le compte-rendu de groupes d'étude sur les besoins métiers en termes de données.

Votre mission est la suivante :

- Qualifier le besoin à partir des demandes métier
- Analyser l'usage des données dans les datamarts des différentes verticales métier
- Concevoir un datawarehouse avec la dimension, l'architecture et le choix des outils technique adaptés au besoin
- Planifier la réalisation du datawarehouse
- Créer l'entrepôt de données
- Intégrer les ETL nécessaires afin d'alimenter l'entrepôt de données
- Communiquer tout au long du projet avec l'ensemble des parties prenantes

Phase 6 - Concevoir et créer un data lake - 105 heures

A la fin de cette phase 6, l'apprenant·e sera capable de par exemple :

- Concevoir et créer un data lake à l'échelle d'une organisation,
- mettre en place une démarche DataOps au sein de l'entreprise pour la gestion des flux de données,
- concevoir et mettre en place une collecte de données massives,
- découvrir les enjeux de cybersécurité et de sécurité des données.

Compétences du référentiel visées par la phase 6

- **C1.** Analyser l'expression d'un besoin de projet data - *niveau 2*
- **C2.** Cartographier les données disponibles - *niveau 2*
- **C3.** Concevoir un cadre technique d'exploitation des données - *niveau 2*
- **C4.** Réaliser une veille technique et réglementaire - *niveau 3*
- **C5.** Planifier la réalisation d'un projet data - *niveau 2*
- **C6.** Superviser la réalisation d'un projet data - *niveau 1*
- **C7.** Communiquer tout au long de la réalisation du projet data - *niveau 3*

- **C12.** Partager le jeu de données en configurant des interfaces logicielles et en créant des interfaces programmables - *niveau 3*
- **C18.** Concevoir l'architecture du data lake - *niveau 3*
- **C19.** Intégrer les différents composants d'infrastructure du data lake - *niveau 3*
- **C20.** Gérer le catalogue des données - *niveau 3*
- **C21.** Implémenter les règles de gouvernance des données - *niveau 3*

Module spécifique de la phase 6 :

“Cybersécurité et sécurité des données” - 14 heures

- Sécuriser les données des interfaces.
- Identifier les données sensibles.
- Gérer les autorisations d'accès.
- Les différents types de risques : menaces internes, erreur humaine, failles logiciel, logiciels malveillants etc.

Activités techniques de la phase 6 :

- Identification des contraintes techniques propres aux sources de données (consulter la documentation, les règles de confidentialité, etc.).
- Inventaire des sources (applications, IoT, ventes, etc.) et des domaines de données utiles au projet data.
- Inventaire des gestionnaires ou responsables des différents domaines (clients, produits, fournisseurs).
- Inventaire des données et métadonnées nécessaires au projet et déjà disponibles, et de leurs structures.
- Inventaire des modalités d'accès, d'autorisation ou encore d'interconnection logiciel aux sources de données identifiées.
- Identification des données manquantes pour le projet data.
- Qualification des flux de données : fréquence et volume des flux.
- Qualification des composants du système d'information existants impliqués dans le cadre technique d'exploitation des données envisagé.
- Formalisation d'une topographie des données
- Sélection des systèmes compatibles avec l'infrastructure et la politique IT de l'organisation
- Sélection des outils batch* nécessaire à la collecte et l'alimentation en données
- Sélection des outils streaming d'acquisition nécessaire à la collecte et l'alimentation en données
- Sélection de l'outil de catalogue* de données adapté au modèle de données et à l'infrastructure du data lake
- Configuration du système de stockage.
- Configuration des outils batch et temps réel.
- Installation de l'outil de catalogue de données.
- Choix de la ou des méthodes d'alimentation du data lake.
- Programmation des procédures d'alimentation automatisées.

- Programmation des procédures de suppression automatique liées au cycle de vie.
- Maintien en condition opérationnelle : mise à jour, intégration des évolutions, etc.
- Paramétrage des droits pour l'alimentation en données.
- Paramétrage des droits pour la recherche sur l'index des données.

Activités transversales de la phase 6 :

- Analyse du besoin exprimé, selon le formalisme de l'acheteur : DCE, brief interne, clauses d'un contrat privé, etc. en suivant un exemple de même nature.
- Questionnement de l'expression de besoin à l'aide d'un guide, et notamment sur les aspects : objectifs du projet, périmètre fonctionnel du projet, moyens humains, techniques et financiers mobilisables.
 - Identification de tous les métiers concernés par le périmètre du projet data suivant : sources et génération des données, collecte et stockage des données, exploitation et analyse des données.
 - Audition des usagers potentiels du projet data pour compléter l'expression du besoin sur les aspects précis d'analyse et d'exploitation des données du projet data
 - Anticipation de l'effort nécessaire et des éventuels freins à lever pour la mise en conformité du projet avec le RGPD, au regard de l'expression de besoin.
 - Inventaire des éventuels besoins spécifiques auprès des futurs usagers du projet data.
 - Anticipation de l'effort d'accessibilité à mettre en oeuvre tout au long du projet
- Conclure sur une recommandation de cadrage du projet data en suivant un modèle de rédaction de préconisations.
- Communiquer le cadrage du projet data au(x) commanditaire(s).
- Organisation d'une veille professionnelle : routine, outils, synthèse, communication.
- Rédaction des spécifications techniques.
- Définition des processus de mise en conformité avec le RGPD.
- Définition de la stratégie d'éco-responsabilité sur l'activité data
- Organisation du pilotage de la réalisation technique (kanban, scrum, gantt...).
- Priorisation et répartition des tâches.
- Planification de la réalisation des tâches (Scrum board, Kanban, etc.).
- Communication des éléments de planification (feuille de route et planification de la production).
- Animation des échanges entre les membres de l'équipe technique en charge de la réalisation du projet.
- Arbitrage et résolution des problèmes bloquant tout au long de la réalisation du projet.
- Suivi des indicateurs d'avancement.
- Communication des résultats et des livrables.
- Accompagnement à la prise en main des outils et services data livrés.
- Rédaction des spécifications techniques.
- Documentation technique.
- Mise en conformité RGPD.

Exemples de sujets pour la veille tout au long de la phase 6 :

- Streaming et collecte de logs
- Gestion des données massives

- Outils de catalogage

Exemple de stacks techniques pour les activités de la phase 6 :

- Languages:
 - Bash
 - Spark (PySpark, ScalaSpark)
- Plateforme :
 - MS (Azure Data Lake Storage, Azure Blob),
 - AWS (S3, Lake Formation)
 - GCP (GCS, BigLake, BigTable)
- Open source :
 - HDFS
 - MongoDB
 - PostgreSQL
 - MariaDB
 - ElasticSearch
 - Apache Hive
- Orchestration, conteneurisation :
 - Docker
 - Kubernetes
 - Airflow
 - Dagster
- Streaming
 - Flume, Kafka

Exemples de situation d'apprentissage pour la phase 6 :

Concevoir et créer un data lake à l'échelle d'une organisation

Vous êtes alternant data engineer pour le compte d'une société de services informatiques.

Votre client, un laboratoire de recherche médicale qui déploie plusieurs modélisations complexes, souhaite automatiser ses flux d'extraction et d'alimentation de données. Pour cela, il fait appel à l'ESN dans laquelle vous travaillez afin de mettre en place un *data lake*.

Vous êtes chargé de concevoir l'architecture du *data lake* répondant à ce besoin, on vous confie le résumé d'échanges oraux et écrits avec le client sur son besoin.

Votre mission est la suivante :

- Formaliser le besoin du client : type et taille de sources données, modèle de données, contraintes techniques et budgétaires, usages prévus
- Concevoir le data lake :
 - Proposer un système compatible avec l'infrastructure et la politique IT du laboratoire
 - Définir une roadmap et une organisation compatible avec le fonctionnement du laboratoire
- Créer le data lake :
 - Sélectionner et paramétrer les outils pour la collecte et l'alimentation en données en prenant en compte en prenant en compte
 - les flux ponctuels (outils batch)

■ les flux continus (outils streaming)

- Superviser l'implémentation d'une solution de catalogage de données par un collaborateur ou un prestataire externe
- Partager des recommandations sur le monitoring et la gestion du data lake
- Documenter, tester, livrer

Mettre en place une démarche DataOps au sein de l'entreprise pour la gestion des flux de données

Vous êtes alternant data engineer pour le compte d'une entreprise du numérique qui commercialise une application.

La culture DevOps est appliquée par les équipes de Développeurs mais pas par les équipes Data : les différents traitements de données ont été mis en place indépendamment les uns des autres. Vous êtes chargé d'optimiser le *data lake* de cette entreprise.

Votre mission est la suivante :

- Cartographier les flux existants en amont et en aval du *data lake*
- Sélectionner et mettre en place un outil d'orchestration des traitements
- Sélectionner et mettre en place le monitoring permettant le suivi des conditions matérielles et applicatives
- Automatiser l'intégration des métadonnées au catalogue
- Mettre en place des procédures de suppression conformes aux contraintes d'accès (notamment réglementaires) et aux contraintes opérationnelles
- Mettre en place des tests automatisés pour l'intégration des évolutions

Concevoir et mettre en place une collecte de données massives

Vous êtes data engineer junior pour le compte d'une startup qui développe une solution innovante basée sur le croisement de données issues de différentes sources dont des objets connectés, l'ensemble représentant des flux quotidiens très importants. On vous confie la tâche de concevoir et développer le système de collecte et de stockage de ces données.

Votre mission est la suivante :

- Sélectionner les systèmes compatibles avec les contraintes et les ressources de la startup
- Sélectionner et implémenter les outils batch et streaming nécessaires à la collecte et l'alimentation en données
- Documenter les procédures de configuration et d'installation
- Structurer l'organisation du *data lake* : normes de nommage, d'archivage, de mise à jour...
- Programmer les flux automatisés d'extraction des données
- Programmer la suppression automatique liées au cycle de vie.
- Mettre en place un monitoring permettant le suivi des traitements de données et générant des alertes pertinentes
- Définir les règles pour le maintien en condition opérationnelle : mise à jour, intégration des évolutions, etc.
- Rédiger le registre des traitements de données personnelles en vue de la mise en conformité du data lake avec le RGPD.

Phase 7 - Mener des missions d'étude, de conseil et d'intégration en systèmes de stockage et big data - 70 heures

Modalité : **en alternance**, une semaine en centre de formation pour 3 semaines en entreprise

Compétences du référentiel visées par la phase 7

- **C1.** Analyser l'expression d'un besoin de projet data - *niveau 3*
- **C2.** Cartographier les données disponibles - *niveau 3*
- **C3.** Concevoir un cadre technique d'exploitation des données - *niveau 3*
- **C4.** Réaliser une veille technique et réglementaire - *niveau 3*
- **C5.** Planifier la réalisation d'un projet data - *niveau 3*
- **C6.** Superviser la réalisation d'un projet data - *niveau 2-3*
- **C7.** Communiquer tout au long de la réalisation du projet data - *niveau 3*

- **C8.** Automatiser l'extraction de données- *niveau 3*
- **C9.** Développer des requêtes de type SQL* d'extraction des données - *niveau 3*
- **C10.** Développer des règles d'agrégation de données issues de différentes sources - *niveau 3*
- **C11.** Créer une base de données - *niveau 3*
- **C12.** Partager le jeu de données en configurant des interfaces logicielles et en créant des interfaces programmables - *niveau 3*

- **C13.** Modéliser la structure des données d'un entrepôt de données - *niveau 3*
- **C14.** Créer un entrepôt de données - *niveau 3*
- **C15.** Intégrer les ETL nécessaires en entrée et en sortie d'un entrepôt de données - *niveau 3*
- **C16.** Gérer l'entrepôt de données - *niveau 3*
- **C17.** Implémenter des variations dans les dimensions de l'entrepôt de données - *niveau 3*

- **C18.** Concevoir l'architecture du data lake - *niveau 3*
- **C19.** Intégrer les différents composants d'infrastructure du data lake - *niveau 3*
- **C20.** Gérer le catalogue des données - *niveau 3*
- **C21.** Implémenter les règles de gouvernance des données - *niveau 3*

Activités techniques de la phase 7 :

Itération sur les activités techniques des phases 5 et 6 en fonction des besoins identifiés et des missions proposées aux apprenants.

Activités transversales de la phase 7 :

- Analyse du besoin exprimé, selon le formalisme de l'acheteur : DCE, brief interne, clauses d'un contrat privé, etc. en suivant un exemple de même nature.
- Questionnement de l'expression de besoin à l'aide d'un guide, et notamment sur les aspects : objectifs du projet, périmètre fonctionnel du projet, moyens humains, techniques et financiers mobilisables.
 - Identification de tous les métiers concernés par le périmètre du projet data suivant : sources et génération des données, collecte et stockage des données, exploitation et analyse des données.
 - Audition des usagers potentiels du projet data pour compléter l'expression du besoin sur les aspects précis d'analyse et d'exploitation des données du projet data
 - Anticipation de l'effort nécessaire et des éventuels freins à lever pour la mise en conformité du projet avec le RGPD, au regard de l'expression de besoin.
 - Inventaire des éventuels besoins spécifiques auprès des futurs usagers du projet data.
 - Anticipation de l'effort d'accessibilité à mettre en oeuvre tout au long du projet
- Conclure sur une recommandation de cadrage du projet data en suivant un modèle de rédaction de préconisations.
- Communiquer le cadrage du projet data au(x) commanditaire(s).
- Organisation d'une veille professionnelle : routine, outils, synthèse, communication.
- Rédaction des spécifications techniques.
- Définition des processus de mise en conformité avec le RGPD.
- Définition de la stratégie d'éco-responsabilité sur l'activité data
- Organisation du pilotage de la réalisation technique (kanban, scrum, gantt...).
- Priorisation et répartition des tâches.
- Planification de la réalisation des tâches (Scrum board, Kanban, etc.).
- Communication des éléments de planification (feuille de route et planification de la production).
- Animation des échanges entre les membres de l'équipe technique en charge de la réalisation du projet.
- Arbitrage et résolution des problèmes bloquant tout au long de la réalisation du projet.
- Suivi des indicateurs d'avancement.
- Communication des résultats et des livrables.
- Accompagnement à la prise en main des outils et services data livrés.

Exemples de sujets pour la veille tout au long de la phase 7 :

- Méthodes agiles avancées : Safe, Shape up, etc.
- Les organisations data : Data-mesh, data-centric...

Stack technique pour la phase 7 :

- SQL, DAX, PySpark
- Microsoft Fabric
- Microsoft PowerBI

Exemples de situation d'apprentissage pour la phase 7 :

Optimiser l'orchestration des flux de transformation de données sur l'ensemble de la chaîne de traitement

Vous êtes data engineer junior pour le compte d'une ESN spécialisée dans la gestion de données, qui a pour client une entreprise du numérique qui commercialise une application de rencontre.

Votre client a connu récemment une croissance rapide de son activité qui a entraîné une hausse du volume de données à traiter. Actuellement, les traitements sont déclenchés à heures fixes, cependant ce fonctionnement n'est plus approprié aux volumes croissants. Le projet consiste à affiner l'orchestration des traitements.

Votre mission est la suivante :

- Schématiser l'intégralité de la chaîne de traitement : extraction et stockage des données brutes, nettoyage et stockage des données transformées.
- Réaliser une veille permettant de proposer un outil d'orchestration approprié
- Concevoir une solution d'orchestration reposant sur l'outil préconisé
- Proposer une feuille de route comprenant :
 - la composition de l'équipe projet
 - le montant et l'allocation du budget
 - les dates de livraisons et échéances principales
 - les indicateurs d'avancement de la mise à jour
 - Rédiger une note sur l'impact de l'intégration de ces données massives sur les indicateurs de service à surveiller pour gérer le data warehouse.
- Superviser la mise en place de l'orchestration des opérations au niveau de l'extraction et du stockage des données brutes
- Superviser la mise en place de l'orchestration des opérations au niveau du nettoyage et du stockage des données transformées

Mettre en place le monitoring d'une infrastructure et proposer une amélioration

Vous êtes alternant data engineer dans une startup. L'infrastructure de données vient d'être mise en place, constituée d'un datawarehouse et d'un data lake.

Il s'agit à présent de mettre en place un monitoring de la chaîne de traitement de données garantissant une remontée d'alerte informative.

Votre mission est la suivante :

- Concevoir le cadre technique de monitoring
- Implémenter la solution de monitoring au niveau de l'extraction et du stockage des données brutes
- Gérer le catalogue de données au niveau du nettoyage et du stockage des données

transformées

Accompagner la réponse à un besoin Data

Vous êtes data engineer freelance. Votre client est un organisme de formation qui dispose de données concernant ses produits, ses clients et ses transactions.

Il fait appel à vous pour professionnaliser et fiabiliser ses flux de traitement de données.

Votre mission est la suivante :

- Dresser un audit du patrimoine de données de votre client : listing des sources, évaluation de qualité
- Inventorier et prioriser les principaux cas d'usage
- Concevoir une solution d'amélioration du flux de traitement des données de votre client
- Communiquer la proposition

Phase 8 - Stage - 665 heures

La pédagogie active promue par Simplon se traduit - entre autres - par l'implication de l'entreprise pendant la formation.

L'entreprise contribue à la formation des apprenants en les recevant pendant une période d'application en entreprise sur 5 mois . Elle est toujours suivie d'un retour en formation pour en acter les apprentissages.

On demande à l'apprenant de réaliser à petite échelle ce qu'il devra faire tout au long de sa vie professionnelle : de la recherche de son entreprise/job, à la compréhension de sa valeur pour une organisation, en passant par l'identification des rapports hiérarchiques. Ce qui implique :

- Organiser sa recherche d'entreprise d'accueil
- Cadrer et anticiper sa période en entreprise de façon cohérente avec la formation
- Intégrer une équipe technique sur des missions du/de data analyst
- Appréhender l'organisation d'une activité professionnelle et économique, dans le domaine de l'analyse de données
- Partager et valoriser son expérience en entreprise
- Mobiliser les acquis de la période en entreprise pour la poursuite de la formation

Compétences travaillées :

- Compétences techniques selon les missions en entreprise
- **CT1.** Planifier le travail à effectuer individuellement et en équipe - *niveau 3*
- **CT2.** Contribuer au pilotage de l'organisation du travail individuel et collectif - *niveau 3*
- **CT3.** Définir le périmètre d'un problème rencontré en adoptant une démarche inductive - *niveau 3*
- **CT4.** Rechercher de façon méthodique des pistes de résolutions au problème rencontré - *niveau 3*
- **CT5.** Partager la solution adoptée en utilisant les moyens de partage de connaissance ou de documentation disponibles - *niveau 3*
- **CT6.** Présenter un travail réalisé en synthétisant ses résultats, sa démarche et en répondant aux questions - *niveau 3*
- **CT7.** Se familiariser avec les codes et la culture propres à son environnement professionnel - *niveau 3*
- **CT8.** Interagir dans un contexte professionnel de façon respectueuse et constructive - *niveau 3*
- **CT9.** Faciliter un temps de travail collectif en assurant une communication constructive entre les participants - *niveau 3*

Préparation à la période d'application en entreprise - 7 heures

- Accompagnement dans la recherche d'entreprise.
- Présentation de l'entreprise d'accueil et les missions associées, à l'oral :
 - Atelier d'analyse pour la compréhension du contexte de l'entreprise et de sa mission
 - En identifiant un ou des enjeu de l'entreprise, et au regard de ses compétences

Période d'application en entreprise - 665 heures

- Prise de poste et intégration
- En fonction des missions, mise en oeuvre des compétences développées lors des modules de formation précédents la période en entreprise
- Rédaction du rapport de stage

Retour en formation après la période d'application en entreprise - 7 heures

- Soutenance orale du rapport de stage de 10 à 15 min devant la promo.
- Reprise de la présentation d'avant stage et on vérifie l'adéquation avec :
 - le contexte
 - les tâches
 - les réponses à la demande : la mobilisation de mes compétences

Phase 9 - Préparation et examen de certification - 70 heures

- revu du projet final, finalisation,
- revu des livrables pour l'examen, finalisation,
- entraînement avec un examen blanc,
- prise en compte des retours et préparation finale,
- clôture de la formation,
- jour-j : examen.

Module spécifique de la phase 9 :

“Passage d'examen ” - 4 heures

“Bilan intermédiaire et final en présence ds stagiaires et de la Région ” - 6 heures

- Échanges préalables entre l'organisme de formation et la Région sans les stagiaires.
- Échanges avec l'organisme de formation, les stagiaires et la Région.
- Tour de table avec prise de parole par chaque stagiaire

Résumé des exemples de mises en situation

- Phase 0 - La prairie - introduction du parcours de formation - 70 heures
 - Faire évoluer un script de collecte et d'agrégation de données
 - Corriger un bug dans l'exécution d'un script de collecte et d'agrégation de données
- Phase 1 - Intervenir sur des ETL et des bases de données les faire évoluer - 168 heures
 - Mettre à jour la procédure d'ETL vers un Datamart
 - Piloter et réaliser la mise à jour d'un contrat d'interface
 - Créer une base de données Open Data à partir d'un Data Warehouse existant
- Phase 2 - Intervenir sur un data warehouse et le faire évoluer - 210 heures
 - Intégrer de nouveaux jeux de données à un data warehouse
 - Ajouter un nouveau pays dans un data warehouse
- Phase 3 - Intervenir sur un data lake et le faire évoluer - 175 heures
 - Connecter un data lake existant à de nouvelles sources de données en respectant le RGPD
 - Augmenter une nouvelle fois la capacité de stockage du data lake
 - Paramétrer les accès au data lake pour une équipe qui en fait la demande
 - Répliquer la mise en place d'un data lake pour un autre client
- Phase 4 - Concevoir et créer des ETL, des bases de données et la mise à disposition des données aux équipes d'analyse - 105 heures
 - Transposer des analyses et/ou visualisations dans une nouvelle plateforme cloud
 - Créer des nouveaux flux de données pour une nouvelle demande métier
- Phase 5 - Concevoir et créer un data warehouse - 105 heures
 - Concevoir un data warehouse à partir de la cartographie des données de l'organisation
 - Améliorer la qualité de données issues d'un flux de traitement existant
 - Organiser et mettre en oeuvre la migration de données depuis une solution On Premise vers le Cloud
- Phase 6 - Concevoir et créer un data lake - 105 heures
 - Concevoir et créer un data lake à l'échelle d'une organisation
 - Mettre en place une démarche DataOps au sein de l'entreprise pour la gestion des flux de données
 - Concevoir et mettre en place une collecte de données massives
 - Élargir l'accès au data lake
- Phase 7 - Mener des missions d'étude, de conseil et d'intégration en systèmes de stockage et big data - 70 heures
 - Optimiser l'orchestration des flux de transformation de données sur l'ensemble de la chaîne de traitement
 - Mettre en place le monitoring d'une infrastructure et proposer une amélioration
 - Accompagner la réponse à un besoin Data
- Phase 8 - Préparation et examen de certification - 70 heures

LA PÉDAGOGIE SIMPLON

Les 6 piliers de la pédagogie Simplon



Notre objectif est de former de bon·ne·s professionnel·le·s maîtrisant la culture du domaine auquel il·le·s sont formé·e·s, détenteur·rice·s des capacités techniques attendues dans le secteur et en capacité de renouveler leurs connaissances, travailler en équipe et résoudre des problèmes complexes.

À cette fin, Simplon met en œuvre une approche active dans ses méthodes d'animation et de formation. La pédagogie dite active, par sa nature, ne vise pas à transmettre de la connaissance - uniquement - mais vise - à Simplon - la montée en compétences des apprenant·e·s. En cela, l'accompagnement et le cadre pédagogique fourni par Simplon ne peut se satisfaire dans la production de contenus théoriques figés ayant pour effet envisageable la transmission d'informations et *in fine* potentiellement de connaissances.

Il s'agit alors de fournir un cadre favorable à la mise en situation des apprenants leur permettant de mobiliser des compétences professionnelles par le faire, notamment au travers de projets pédagogiques et d'activités pédagogiques reprenant des contextes d'entreprises.

Ce cadre est garanti par une méthodologie bien définie, dont les grandes lignes sont :

- un cadre de conception des projets pédagogiques formalisé et disponible sur la plateforme en ligne d'apprentissage de Simplon, Simponline.
- une évaluation des acquis tout au long de la formation,
- l'apprentissage par la collaboration et l'entraide,
- un accompagnement vers l'autonomie et l'apprendre à apprendre.

Les apports théoriques ne sont pas dispensés à part, à côté de la pratique ; mais bien tout au long du parcours de formation, toujours en lien avec le besoin d'apprendre lui-même provenant du besoin de faire.

En synthèse, la pédagogie Simplon c'est :


- Une pédagogie active : mise en pratique, apprentissage par projets, co-apprentissage, etc.
- Une équipe pluridisciplinaire : le formateur·rice référent·e, des expert·e·s techniques, un·e “chargé·e de médiation emploi” ainsi qu'un·e responsable de formation.
- L'entreprise au cœur du parcours : parrainage de promotion, mentorat inversé, périodes d'immersion, simulations d'entretien, job dating, meet up, etc.

Pour chaque compétence, la progression est divisée en trois niveaux :

- Niveau 1 - *imiter*
- Niveau 2 - *adapter*
- Niveau 3 - *transposer*

On considère une compétence acquise lorsque le troisième niveau est atteint.

La montée en compétence se concrétise lors de réalisations de projets d'apprentissage et de projets d'application :



Les adaptations à l'oeuvre pour les formation hybrides et distancielles

Le contexte sanitaire de 2020 oblige les entreprises mais aussi les centres de formation à réinventer leurs organisations.

Dans le cas où le projet de formation intègre du distanciel, le ou la formateur·rice donne un cadre pédagogique et accompagne les apprenant·es selon la même pédagogie Simplon assurée en présentiel : pédagogie active, par projets (pédagogiques), avec une approche par compétences.

Cette pédagogie sera mise en œuvre de sorte à pouvoir accompagner au mieux les apprentissages de chaque apprenant·e en tenant compte des contraintes imposées par les conditions hybrides ou distancielles. La nature de l'adaptation de l'accompagnement reçu par

chaque apprenant.e ne sera pas uniforme à l'échelle de la promotion, ni à l'échelle de la durée de la formation. C'est une forme de différenciation pédagogique.

La nature des modalités pédagogiques d'accompagnement et d'évaluation sont adaptées selon le format contraint par la situation et les besoins des apprenant.e.s. Les critères de différenciation pédagogique sont définis au préalable par l'équipe pédagogique. Les semaines types présentées plus loin dans le document sont construites à titre d'exemple selon les critères suivants, eux aussi, donnés à titre d'exemple :

- niveau d'autonomie des apprenant.e.s,
- introduction d'un nouvel outil,
- niveau de compétence des apprenant.e.s.

Finalement, la différenciation pédagogique, c'est ce qui permet de garantir, en pédagogie Simplon, un suivi régulier et de qualité des apprentissages, selon les besoins et les contraintes de chaque apprenant.e, dans un contexte de formation hybride ou distanciel.

LES MOYENS PÉDAGOGIQUES ET TECHNIQUES

La formation en présentiel à lieu dans les salles de formations de Simplon.co, elles sont toutes équipées :

- de tables et de chaises
- d'une connexion internet
- d'un vidéoprojecteur

Chaque apprenant se voit attribuer un ordinateur portable pour toute la durée de la formation.

Les conditions de suivi de la formation à distance doivent être favorables aux apprentissages. Si besoin et si la situation sanitaire le permet, des solutions peuvent être proposées aux apprenant.e.s (prêt de matériel , dépannage connexion, suivi spécifique, ...).

Les outils utilisés en formation sont :

- Simplonline, notre plateforme d'apprentissage en pédagogie active et par projets permet de cadrer le travail à faire, évaluer la montée en compétence et suivre la progression collective et individuelle.
- Discord est la solution à Simplon pour les échanges au sein d'une promotion. Une promotion Simplon dispose de son salon Discord dédié dans le Discord des Alumnis, ce qui permet la continuité post-formation. À privilégier pour toute discussion en synchrone. Il y a aussi la possibilité de s'appeler à plusieurs, de streamer etc.
- Google Meet vous permet d'organiser depuis l'agenda Google des sessions de vidéoconférence avec les apprenants. Nous vous conseillons de réaliser des sessions successives par petits groupes d'apprenant.e.s pour plus d'efficacité.
- D'autres outils permettant de faciliter l'accompagnement ou l'animation de la formation à distance sont disponibles pour les formateur.rice.s, notamment : kahoot, Quizizz, trello, ...

L'ENCADREMENT PÉDAGOGIQUE

La formation est assurée par au moins un formateur sinon plusieurs, dont un formateur référent.

Chaque formateur doit suivre une formation de formateur assurée par Simplon.co.

Les apprenants sont encadrés par une équipe pédagogique pluridisciplinaire :

- Un.e formateur.rice référent.e de la formation
- Un.e ou deux formateur.rice.s en appui
- Un.e chargé.e de promo/chargé.e de médiation emploi
- L'assiduité des apprenants est suivie grâce à la signature de feuille d'émargement


L'équipe :

- Informe les prescripteurs et le public, détecte des talents et les sélectionne
- Définit les étapes de la progression des apprenants
- Organise les interventions de chacun auprès des promos
- Facilite l'acquisition des savoirs et compétences
- Garantit la mise en oeuvre des principes pédagogiques de SIMPLON
- Accompagne les apprenants dans leur insertion professionnelle
- Concourt à valoriser la marque SIMPLON auprès de tous les intervenants

De façon spécifique dans le cas où la formation devrait intégrer des temps à distance

- Chaque formateur.rice doit suivre le module de formation "hybride/distanciel"
- L'assiduité des apprenant.e.s est suivi grâce à un outil dédié

UNE JOURNÉE TYPE

**Lancement**

Le formateur lance les unités d'apprentissage. Il peut en profiter pour sonder le moral des apprenant-e-s, réaliser une activité de cohésion de groupe ou un réveil pédagogique.

Cas pratique ou mise en situation

Nos formations s'articulent autour de situations d'apprentissage dont les modalités pédagogiques sont précisées par le formateur. En effet, il indique aux apprenant-e-s si la situation doit être réalisée **individuellement ou en groupe, précise les contraintes de temps, les outils de collaboration à utiliser**, etc. Il peut être sollicité à tout moment de réalisation de la mise en situation par les apprenant-e-s et lever les points de blocages individuels ou collectifs selon les modalités qui lui semblent les plus adaptées (rappel théorique individuel ou en groupe, mix des groupes, activité guidée...).

Remédiation *(pas nécessairement quotidienne)*

À l'issue de certaine situation d'apprentissage, **un temps de "remédiation" en collectif** permet de faire le point sur les tâches réalisées, les ressources théoriques associées et comment elles ont été mobilisées pour dépasser l'obstacle rencontré.

Routine pédagogique


À cela s'ajoutent, des **rituels de réveil pédagogique, de veille et d'analyse réflexive** permettant de faire réfléchir le stagiaire sur ce qu'il a appris, fait, acquis grâce à la situation.

L'ÉVALUATION PÉDAGOGIQUE À SIMPLON

Les apprenant-e-s sont évalué-e-s tout au long de la formation, sur leur capacité à agir en situation d'apprentissage, simulation de l'activité professionnelle visée par la formation. Toutes ces réalisations constituent leur premier "portfolio" et démontrent leur capacité à être efficient dans un environnement de travail.

Les briefs de ces situations sont construits et proposés par les formateurs depuis notre plateforme d'apprentissage *Simplonline*. Cette plateforme permet également le partage de ressources pédagogiques entre tous les membres de la plateforme (apprenants et formateurs). L'apprenant prend donc connaissance des briefs : objectifs, modalités, évaluation, etc. tout en s'aidant des ressources disponibles. Il peut par la suite y consulter sa progression, dans l'acquisition des compétences, visées par la formation.

L'évaluation des compétences se fait de façon continue et terminale :



*Le chef d'œuvre correspond au projet de fin de parcours, soutenu lors de l'évaluation finale devant un jury.